

```
In [1]: 1 import numpy as np
        2 import matplotlib.pyplot as plt
        3 from scipy.stats import maxwell
        4 import scipy.stats as sts
        5 from scipy.stats import geom
        6 from random import random
        7 from collections import Counter
        8 import copy
        9 import math
       10 from math import *
       11 from random import *
       12 import pandas as pd
       13 import calendar
       14 import statsmodels.api as sm
       15
       16 plt.style.use('ggplot') # Красивые графики
       17 plt.rcParams['figure.figsize'] = (15, 5) # Размер картинок
```

Содержание

1. [Теоретическое введение](#)
2. [Геометрическое распределение](#)
3. [Распределение Максвелла](#)

Теоретическое введение

Выборочное среднее и выборочная дисперсия

Наиболее важными характеристиками случайной величины ξ являются ее моменты $\alpha_k = M\xi^k$, а также центральные моменты $\mu^k = M(\xi - \alpha_1)^k$ (когда они существуют). Их статистическими аналогами, вычисляемыми по соответствующей выборке $X = (X_1, \dots, X_n)$, являются выборочные моменты соответственно обычные:

$$\hat{\alpha}_k = \frac{1}{n} \sum_{i=1}^n X_i^k$$

и центральные:

$$\hat{\mu}_k = \frac{1}{n} \sum_{i=1}^n (X_i - \hat{\alpha}_1)^k$$

$\hat{\alpha}_1$ (принято обозначать, как \overline{X}) называют выборочным средним, μ^2 - выборочной дисперсией. Таким образом, выборочное среднее и выборочная дисперсия являются статистическими аналогами теоретических среднего (математического ожидания) $M\xi$ и дисперсии $D\xi$, когда они существуют.

Найдем математическое ожидание и дисперсию выборочного среднего и выборочной дисперсии:

$$M\bar{X} = \frac{1}{n} \sum_{i=1}^n MX_i = M\xi = \alpha_1$$

$$D\bar{X} = \frac{1}{n^2} \sum_{i=1}^n DX_i = \frac{1}{n} D\xi = \frac{\mu_2}{n}$$

Для выборочной дисперсии введем обозначение: $Y_i = X_i - \alpha_1$:

$$S^2 = \hat{\mu}_2 = \frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2 = \frac{1}{n} \sum_{i=1}^n Y_i^2 - \bar{Y}^2$$

Поскольку $MY_i = 0$, $MY_i^2 = \mu_2$ и $MY_iY_j = MY_jY_i = 0$, ($i \neq j$), то:

$$M\bar{Y}^2 = \frac{1}{n^2} \sum_{i,j=1}^n MY_iY_j = \frac{1}{n^2} \sum_{i=1}^n MY_i^2 = \frac{\mu_2}{n}$$

Отсюда следует, что

$$MS^2 = \frac{n-1}{n} \mu_2$$

Перейдём к вычислению DS^2

$$(S^2)^2 = \frac{1}{n^2} \left(\sum_{i=1}^n Y_i^2 \right)^2 - \frac{2}{n} \bar{Y}^2 \sum_{i=1}^n Y_i^2 + \bar{Y}^4$$

Так как случайные величины Y_1, \dots, Y_n независимы и $MY_i = 0$, то в правой части равенства

$$M\bar{Y}^4 = \frac{1}{n^4} (n\mu_4 + 3n(n-1)\mu_2^2) = \frac{\mu_4 + 3(n-1)\mu_2^2}{n^3}$$

Аналогично находим

$$\frac{1}{n^2} M \left(\sum_{i=1}^n Y_i^2 \right) = \frac{\mu_4 + (n-1)\mu_2^2}{n} = M(\bar{Y}^2 \sum_{i=1}^n Y_i^2)$$

С учётом этих соотношений по формуле

$$DS^2 = M(S^2)^2 - (MS^2)^2$$

Теперь рассмотрим свойства выборочных среднего и дисперсии при неограниченном возрастании объема выборки n , которые дадут нам ответ на вопрос, оценками каких параметров рапределений они являются. Чтобы подчеркнуть зависимость моментов $\hat{\alpha}_k, \hat{\mu}_k$ от объема выборки, будем в дальнейшем приписывать дополнительный индекс n : $\hat{\alpha}_{nk}, \hat{\mu}_{nk}$

$$M\hat{\alpha}_{nk} = \frac{1}{n} \sum_{i=1}^n MX_i^k = M\xi^k = \hat{\alpha}_k$$

$$D\hat{\alpha}_{nk} = \frac{1}{n^2} \sum_{i=1}^n DX_i^k = \frac{1}{n} D\xi^k = \frac{1}{n} (M\xi^{2k} - (M\xi^k)^2) = \frac{\alpha_{2k} - \alpha_k^2}{n}$$

На основании неравенства Чебышева, отсюда следует, что для любого $\epsilon > 0$ при $n \rightarrow \infty$

$$P|\hat{\alpha}_{nk} - \alpha_k| < \epsilon \rightarrow 1$$

т.е. выборочный момент $\hat{\alpha}_{nk}$ сходится по вероятности при $n \rightarrow \infty$ к соответствующему теоретическому моменту α_k . Таким образом, $\hat{\alpha}_{nk}$ можно использовать в качестве оценки α_k , когда объем выборки достаточно велик. Аналогичное утверждение справедливо и для центральных моментов:

$$P|\mu_{nk} - \mu_k| < \epsilon \rightarrow 1$$

т.е. μ_{nk} можно использовать в качестве оценки μ_k , когда объем выборки достаточно велик.

1. Оценка $\hat{\theta}(X)$ параметра θ называется несмещенной, если:

$$E(\hat{\theta}(X)) = \theta$$

2. Оценка $\hat{\theta}(X) = \hat{\theta}_n(X_1, \dots, X_n)$ параметра θ называется состоятельной, если при $n \rightarrow \infty$ соблюдается:

$$\hat{\theta}_n(X_1, \dots, X_n) \xrightarrow{p} \theta$$

При этом для проверки состоятельности достаточно убедиться, что соблюдены следующие два условия:

$$\lim_{n \rightarrow \infty} E(\hat{\theta}_n(X_1, \dots, X_n)) = \theta$$

$$\lim_{n \rightarrow \infty} Var(\hat{\theta}_n(X_1, \dots, X_n)) = 0$$

Выборочное среднее является несмещенной оценкой для теоретического математического ожидания.

$$\hat{\alpha}_1 = \frac{1}{n} \sum_{i=1}^n X_i$$

$$M\hat{\alpha}_1 = M\left(\frac{1}{n} \sum_{i=1}^n x_i\right) = \frac{1}{n} \cdot n \cdot MX = MX$$

$$M\hat{\alpha}_1 = MX$$

Выборочное среднее является состоятельной оценкой для теоретического математического ожидания.

$$\hat{\alpha}_1 = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\lim_{n \rightarrow \infty} \hat{\alpha}_1 = \lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n X_i = \lim_{n \rightarrow \infty} \frac{1}{n} \cdot n \cdot MX = MX$$

Выборочная дисперсия S^2 является состоятельной и несмещенной оценкой для теоретической дисперсии.

$$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2$$

Продолжим исследование свойств выборочных моментов для больших выборок и рассмотрим теперь асимптотическое поведение их выборочных распределений.

Если распределение случайной величины v_n сходится при $n \rightarrow \infty$ к распределению случайной величины v и при этом $\zeta(v) = N(\mu, \sigma^2)$, то будем писать $\zeta(v_n) \rightarrow N(\mu, \sigma^2)$. Далее иногда будем говорить, что случайная величина v_n асимптотически нормальна $N(\mu_n, \sigma_n^2)$, и записывать это следующим образом:

$\zeta(v_n) \approx N(\mu_n, \sigma_n^2)$, если $\zeta(\frac{v_n - \mu_n}{\sigma_n}) \rightarrow N(0, 1)$.

Найдем сначала асимптотические распределения выборочных моментов $\hat{\alpha}_{nk}$. Величина $n\hat{\alpha}_{nk} = \sum_{i=1}^n X_i^k$ является суммой независимых одинаково распределенных случайных величин. Если конечен момент $\alpha_{2k} = M\xi^{2k}$, то к этой сумме можно применить центральную предельную теорему теории вероятностей. Так как $MX_i^k = \alpha_k$, $DX_i^k = \alpha_{2k} - \alpha_k^2$, то величина

$$\frac{n\hat{\alpha}_{nk} - n\alpha_k}{\sqrt{n(\alpha_{2k} - \alpha_k^2)}} = \frac{\hat{\alpha}_{nk} - \alpha_k}{\sqrt{\frac{\alpha_{2k} - \alpha_k^2}{n}}}$$

асимптотически нормальна $N(0, 1)$. Таким образом справедлива следующая теорема:

Если конечен теоритический момент α_{2k} , то при $n \rightarrow \infty$ выборочный момент $\hat{\alpha}_{nk}$ асимптотически нормален $N(\alpha_k, \frac{\alpha_{2k} - \alpha_k^2}{n})$

Из теоремы следует, что если существует теоретическая дисперсия, то выборочное среднее $\hat{\alpha}_{n1}$ асимптотически нормально $N(\alpha_1, \frac{\mu_2}{n})$

Из теоремы об асимптотической нормальности функций от выборочных моментов следует, что асимптотически нормальными являются и центральные выборочные моменты $\hat{\mu}_{nk}$, поскольку они являются непрерывными функциями (многочленами) от обычных выборочных моментов.

Доверительный интервал

Определение: γ - доверительным интервалом для g называется такой случайный интервал $(T_1(X), T_2(X))$, $T_1(X) < T_2(X)$, который содержит внутри себя (накрывает) неизвестное значение g с вероятностью, не меньшей γ :

$$P\{T_1(X) < g < T_2(X)\} \geq \gamma$$

Здесь $T_1(X)$ и $T_2(X)$ - некоторые статистики (функции от выборки), называемые соответственно нижней и верхней доверительными границами, а γ - задаваемый заранее доверительный уровень, который обычно выбирается близким к 1. Длина доверительного интервала характеризует точность локализации оцениваемой характеристики g , а величина γ является показателем надежности доверительного интервала.

В сформулированной ранее теореме [Если конечен теоретический момент α_{2k} , то при $n \rightarrow \infty$ выборочный момент $\hat{\alpha}_{nk}$ асимптотически нормален $N(\alpha_k, \frac{\alpha_{2k} - \alpha_k^2}{n})$] можно заменить асимптотическую дисперсию $\frac{\alpha_{2k} - \alpha_k^2}{n}$ ее оценкой $\frac{\hat{\alpha}_{n,2k} - \hat{\alpha}_{nk}^2}{n}$. Это дает искомый асимптотический γ -доверительный интервал для момента α_k вида:

$$(\hat{\alpha}_{nk} \mp c_\gamma \sqrt{\frac{\hat{\alpha}_{n,2k} - \hat{\alpha}_{nk}^2}{n}})$$

Полагая здесь $k = 1$, получим соответствующий интервал для теоретического среднего $\alpha_1 = M\xi$:

$$(\bar{X} \mp \frac{c_\gamma S}{\sqrt{n}})$$

Чтобы построить асимптотический γ -доверительный интервал для теоретической дисперсии $\mu_2 = D\xi$, надо просто воспользоваться результатом теоремы об асимптотической нормальности выборочной дисперсии $[\zeta(\frac{\sqrt{n}(S^2 - \mu_2)}{\sqrt{\hat{\mu}_{n4} - S^4}}) \rightarrow N(0, 1)]$:

искомый интервал есть

$$(S^2 \mp c_\gamma \sqrt{\frac{\hat{\mu}_{n4} - S^4}{n}})$$

Оптимальность оценок

Для построения теории оптимального оценивания прежде всего надо договориться о мере точности оценок, т.е. уточнить смысл приближенного равенства $T(X) \approx g$. Если статистика $T(x)$ используется для оценивания g , то одной из разумных мер расхождения между ними является $(T(X) - g)^2$, или квадратичная ошибка. Но так как это величина случайная используется среднеквадратичная ошибка (с. к. о.) $\Delta(T) = M(T(X) - g)^2$.

Определение: Оценка минимизирующая с. к. о. в данном классе оценок T_g называется оптимальной в среднеквадратичном смысле и обозначается T^* :

$$T^* = \operatorname{argmin}_{T \in T_g} \Delta(T)$$

Пусть требуется оценить заданную параметрическую функцию $\tau(\theta)$ в модели $F = F(x; \theta)$, $\theta \in \Theta$ по соответствующей выборке $X = (X_1, \dots, X_n)$. Обозначим τ_τ класс всех несмещенных оценок $T = T(X)$ для $\tau(\theta)$ и предположим, что он не пуст. Дополнительно предположим, что дисперсии всех оценок из класса τ_τ конечны: $D_\theta T = M_\theta(T - \tau(\theta))^2 < \infty$, в этом случае мерой точности оценок является их дисперсия.

Утверждение: Для несмещенных оценок среднеквадратичное отклонение совпадает с ее дисперсией, а для смещенной оценки больше ее дисперсии.

Доказательство:

$$M_\theta(T - \tau)^2 = M(T - MT + MT - \tau)^2 = M(T - MT)^2 + M(MT - \tau)^2 + 2M((T - MT)(MT - \tau)) = DT + b^2 = 0 \Leftrightarrow MT = \tau$$

Теорема Рао-Блэкуэлла-Колмогорова: Оптимальная оценка, если она существует, является функцией от достаточной статистики.

По определению достаточная статистика $T = T(X)$ называется полной, если для всякой функции $\varphi(T)$ из того, что

$$M_\theta \varphi(T) = 0, \forall \theta$$

следует $\varphi(t) \equiv 0$ на всем множестве значений статистики T .

Теорема: Если существует полная достаточная статистика, то всякая функция от нее является оптимальной оценкой своего математического ожидания.

Итак, пусть существует полная достаточная статистика $T = T(X)$ и требуется оценить заданную параметрическую функцию $\tau(\theta)$.

Тогда:

- 1) Если существует какая-то несмещенная оценка $\tau(\theta)$, то существует и несмещенная оценка, являющаяся функцией от T ; можно так же сказать, что если нет несмещенных оценок вида $H(T)$, то класс несмещенных оценок τ_τ для $\tau(\theta)$ пуст;
- 2) оптимальная (н.о.р.м.д.) оценка когда она существует, всегда является функцией от T и она однозначно определяется уравнением $M_\theta H(T) = \tau(\theta)$

Оптимальная оценка T^* является функцией от T и определяется уравнением

3.1. Геометрическое распределение

```
In [2]: 1 # Создание случайной величины с геометрическим распределением, зависящим
        2 # от параметра p
        3 p = 0.5
        4 geom_rv = sts.geom(n)
```

```
In [3]: 1 #Генерация выборки объема n = 5 с выводом
        2 for n in [5]:
        3     means_5 = []
        4     for i in range(5):
        5         sample = geom_rv.rvs(n)
        6         means_5.append(sample)
        7         print(sample)
```

```
[2 1 1 1 2]
[1 1 2 3 1]
[3 1 1 1 2]
[1 3 1 3 3]
[2 7 1 3 3]
```

```
In [4]: 1 #Генерация выборки объема n = 10 с выводом
        2 for n in [10]:
        3     means_10 = []
        4     for i in range(5):
        5         sample = geom_rv.rvs(n)
        6         means_10.append(sample)
        7         print(sample)
```

```
[3 3 2 2 1 1 1 1 1 1]
[1 1 1 1 2 1 3 3 1 2]
[1 5 1 1 4 1 1 1 1 2]
[1 3 1 2 1 4 3 2 1 2]
[2 1 4 1 1 3 7 3 1 2]
```

```
In [5]: 1 #Генерация выборки объема n = 100 ,без вывода
        2 for n in [100]:
        3     means_100 = []
        4     for i in range(5):
        5         sample = geom_rv.rvs(n)
        6         means_100.append(sample)
```

```
In [6]: 1 #Генерация выборки объема n = 1000 ,без вывода
        2 for n in [1000]:
        3     means_1000 = []
        4     for i in range(5):
        5         sample = geom_rv.rvs(n)
        6         means_1000.append(sample)
```

```
In [7]: 1 #Генерация выборки объема n = 100000 ,без вывода
        2 for n in [100000]:
        3     means_100000 = []
        4     for i in range(5):
        5         sample = geom_rv.rvs(n)
        6         means_100000.append(sample)
```

3.1.1 Нахождение выборочного среднего и выборочной дисперсии геометрического распределения

Выборочное среднее

In [8]:

```
1 #n=5
2 vs_5 = []
3 for i in range(5):
4     vs_5.append(np.mean(means_5[i]))
5 print(vs_5)
6 #n=10
7 vs_10 = []
8 for i in range(5):
9     vs_10.append(np.mean(means_10[i]))
10 print(vs_10)
11 #n=100
12 vs_100 = []
13 for i in range(5):
14     vs_100.append(np.mean(means_100[i]))
15 print(vs_100)
16 #n=1000
17 vs_1000 = []
18 for i in range(5):
19     vs_1000.append(np.mean(means_1000[i]))
20 print(vs_1000)
21 #n=100000
22 vs_100000 = []
23 for i in range(5):
24     vs_100000.append(np.mean(means_100000[i]))
25 print(vs_100000)
```

[1.4, 1.6, 1.6, 2.2, 3.2]

[1.6, 1.6, 1.8, 2.0, 2.5]

[2.23, 2.19, 1.97, 2.09, 1.89]

[1.949, 2.038, 1.993, 1.942, 1.977]

[1.99304, 2.00094, 1.99217, 1.99835, 2.00392]

$$M_{\xi} = \frac{1}{p}, \text{ при } p = 0.5 \quad M_{\xi} = 2$$

```
In [9]: 1 #Сравнение  
        2 p = 0.5  
        3 geom_stats(n_moments = 'm')
```

```
Out[9]: array(2.)
```

Выборочная дисперсия

In [10]:

```
1 #n=5
2 vd_5 = []
3 for i in range(5):
4     vd_5.append(round(np.var(means_5[i]),6))
5 print(vd_5)
6 #n=10
7 vd_10 = []
8 for i in range(5):
9     vd_10.append(round(np.var(means_10[i]),6))
10 print(vd_10)
11 #n=100
12 vd_100 = []
13 for i in range(5):
14     vd_100.append(round(np.var(means_100[i]),6))
15 print(vd_100)
16 #n=1000
17 vd_1000 = []
18 for i in range(5):
19     vd_1000.append(round(np.var(means_1000[i]),6))
20 print(vd_1000)
21 #n=100000
22 vd_100000 = []
23 for i in range(5):
24     vd_100000.append(round(np.var(means_100000[i]),6))
25 print(vd_100000)
```

[0.24, 0.64, 0.64, 0.96, 4.16]

[0.64, 0.64, 1.96, 1.0, 3.25]

[2.1371, 3.7939, 2.1491, 2.4019, 1.9979]

[1.984399, 2.132556, 1.824951, 1.734636, 2.008471]

[1.973252, 2.001179, 1.984249, 2.009987, 2.025725]

$$D\xi = \frac{q}{p^2} = \frac{1-p}{p^2}$$

При $p = 0.5$, $D\xi = 2$

```
In [11]: 1 #Сравнение
          2 geom_stats(n_moments = 'v')
```

```
Out[11]: array(2.)
```

Как видно из полученных значений, чем больше объём выборки, тем менее отличаются выборочное среднее от теоретического математического ожидания и выборочная дисперсия от теоретической дисперсии

3.1.2 Построение доверительного интервала для выборочного среднего

Положим $\gamma = 0.95$ и найдем доверительный интервал для выборочного среднего.

$$\Phi(c_\gamma) = \frac{\gamma}{2} = 0.475$$

Из таблицы значений функции Лапласа $c_\gamma \approx 1.96$

In [12]:

```
1 #n=5
2 print('n = 5')
3 for i in range(5):
4     print('(', vs_5[i], '-+ 1.96 *', np.sqrt(vd_5[i]/5), ') = (', vs_5[i], '-+', round(1.96*np.s
5 #n=10
6 print('n = 10')
7 for i in range(5):
8     print('(', vs_10[i], '-+ 1.96 *', np.sqrt(vd_10[i]/10), ') = (', vs_10[i], '-+', round(1.96*n
9 #n=100
10 print('n = 100')
11 for i in range(5):
12     print('(', vs_100[i], '-+ 1.96 *', np.sqrt(vd_100[i]/100), ') = (', vs_100[i], '-+', round(1
13 #n=1000
14 print('n = 1000')
15 for i in range(5):
16     print('(', vs_1000[i], '-+ 1.96 *', np.sqrt(vd_1000[i]/1000), ') = (', vs_1000[i], '-+', rou
17 #n=100000
18 print('n = 100000')
19 for i in range(5):
20     print('(', vs_100000[i], '-+ 1.96 *', np.sqrt(vd_100000[i]/100000), ') = (', vs_100000[i], '
```

```
n = 5
( 1.4 -+ 1.96 * 0.21908902300206645 ) = ( 1.4 -+ 0.429414 )
( 1.6 -+ 1.96 * 0.35777087639996635 ) = ( 1.6 -+ 0.701231 )
( 1.6 -+ 1.96 * 0.35777087639996635 ) = ( 1.6 -+ 0.701231 )
( 2.2 -+ 1.96 * 0.4381780460041329 ) = ( 2.2 -+ 0.858829 )
( 3.2 -+ 1.96 * 0.9121403400793104 ) = ( 3.2 -+ 1.787795 )
n = 10
( 1.6 -+ 1.96 * 0.25298221281347033 ) = ( 1.6 -+ 0.495845 )
( 1.6 -+ 1.96 * 0.25298221281347033 ) = ( 1.6 -+ 0.495845 )
( 1.8 -+ 1.96 * 0.4427188724235731 ) = ( 1.8 -+ 0.867729 )
( 2.0 -+ 1.96 * 0.31622776601683794 ) = ( 2.0 -+ 0.619806 )
( 2.5 -+ 1.96 * 0.570087712549569 ) = ( 2.5 -+ 1.117372 )
n = 100
( 2.23 -+ 1.96 * 0.14618823482072693 ) = ( 2.23 -+ 0.286529 )
( 2.19 -+ 1.96 * 0.19477936235648785 ) = ( 2.19 -+ 0.381768 )
```

*Округлено до 6 знаков после запятой.

3.1.3 Нахождение оптимальности рассматриваемых оценок

Условия регулярности:

1) Так как $0 < \theta < 1$, то $L(\bar{x}, \theta) > 0$. Функция дифференцируема по θ .

2) Воспользуемся равенством:

$$i_n(\theta) = M_\theta V^2(X; \theta) = n * i(\theta)$$

Найдём $i(\theta)$:

$$i(\theta) = -M_\theta \frac{\partial^2 (\ln f_\theta(x_1))}{\partial \theta^2}$$

$$\frac{\partial^2 (\ln(f(x_1, \theta)))}{\partial \theta^2} = \frac{\partial^2 (x \ln((1 - \theta)\theta))}{\partial \theta^2}$$

Первая производная:

$$\frac{x\theta + \theta - 1}{(\theta - 1)\theta}$$

Вторая производная:

$$-\frac{\theta^2(x + 1) + 2\theta - 1}{(\theta - 1)^2 \theta^2}$$

$$M(x) = \frac{1 - \theta}{\theta}$$

$$M_\theta\left(\frac{\theta^2(x + 1 + 2\theta - 1)}{(\theta - 1)^2 \theta^2}\right) = M_\theta\left(\frac{\theta^2 x}{(\theta - 1)^2 \theta^2}\right) + \frac{\theta + 2\theta - 1}{(\theta - 1)^2 \theta^2} = \left(\frac{\theta^2 M(x)}{(\theta - 1)^2 \theta^2}\right) + \frac{3\theta - 1}{(\theta - 1)^2 \theta^2} = \left(-\frac{\theta^2(1 - \theta)}{(\theta - 1)^2 \theta^3}\right) + \frac{3\theta - 1}{(\theta - 1)^2 \theta^2}$$

$$-\frac{1}{(\theta - 1)\theta} + \frac{3\theta - 1}{(\theta - 1)^2 \theta^2} = -\frac{\theta^2 - 4\theta + 1}{(\theta - 1)^2 \theta^2}$$

В силу того, что $0 < \theta < 1$, то информация Фишера конечна, следовательно, свойство выполняется.

3) Выборочное среднее не зависит от параметра θ , то свойство выполняется.

$$f(x) = (1 - p)^x p$$

Запишем логарифмическую функцию правдоподобия:

$$L(\bar{x}; \theta) = \prod_{i=1}^n (1 - \theta)^{x_i} \theta$$

Прологарифмируем обе части:

$$\begin{aligned} \ln L(\bar{x}; \theta) &= \sum_{i=1}^n \ln(1 - \theta)^{x_i} \theta = \sum_{i=1}^n \ln(\theta) + \sum_{i=1}^n \ln((1 - \theta)^{x_i}) \\ \frac{\partial(\ln(L(x, \theta)))}{\partial \theta} &= \sum_{i=1}^n \left(\frac{1}{\theta}\right) + \sum_{i=1}^n \left(-\frac{x_i}{1 - \theta}\right) \end{aligned}$$

Так как

$$\sum_{i=1}^n \left(\frac{x_i}{1 - \theta}\right) = \sum_{i=1}^n \left(\frac{1}{\theta}\right), \theta \neq 0; 1,$$

то

$$\begin{aligned} \frac{1}{1 - \theta} \bar{X} &= \frac{1}{\theta} \\ \bar{X} &= \frac{1 - \theta}{\theta} \\ M\left(\frac{1 - \theta}{\theta}\right) &= M\bar{X} = M\xi \end{aligned}$$

А значит, оценка несмещенная. Также оценка является состоятельной, в силу того, что

$$M\bar{X} \xrightarrow[n \rightarrow \infty]{P} \bar{X}$$

Теперь приступим к оцениванию эффективности данной оценки:

Вспомним, что

$$-M_{\theta} \frac{\partial^2(\ln(f_{\theta}(X_1)))}{\partial \theta} = i_1(\theta)$$

f(x) геометрического распределения можно дважды продифференцировать.

3.2 Распределения Максвелла

```
In [13]: 1 # Создание случайной величины с распределением Максвелла, зависящим
          2 # от параметра lambda
          3 lambda=1.0
          4 maxwell_rv=sts_maxwell(scale=lambda)
```

```
In [14]: 1 #Генерация выборки объема n = 5 с выводом
          2 for n in [5]:
          3     means__5=[]
          4     for i in range(5):
          5         sample=maxwell_rv.rvs(n)
          6         means__5.append(sample)
          7         print(sample)

[2.41609712 1.76922215 1.5930344  1.83891646 2.32443766]
[1.91594045 1.51313849 2.17701851 2.98251721 1.74690197]
[0.54612996 1.82129461 2.12808232 1.87961106 0.53487278]
[1.58352172 1.74733789 2.13514589 2.59575027 2.23143757]
[0.86938855 0.91584446 2.23479136 0.67373006 1.37449349]
```

In [15]:

```
1 #Генерация выборки объема n = 10 с выводом
2 for n in [10]:
3     means__10=[]
4     for i in range(5):
5         sample=maxwell_rv.rvs(n)
6         means__10.append(sample)
7         print(sample)
```

[1.29333112 2.49794698 0.39525199 2.28555043 0.44500091 2.38964386
1.30222352 2.28941905 1.25920271 0.90757726]
[0.2591424 0.3525709 1.56350926 2.61469714 1.67857905 1.5425198
1.1630406 0.3912105 1.628316 1.65754265]
[1.73446419 1.28225808 1.62562587 1.88573595 1.72514081 1.35559837
1.32751044 0.87079062 3.27650123 2.19524686]
[0.91181159 1.58967585 0.6389368 2.57554735 1.87469683 1.5959847
0.94075626 1.0759609 2.43485971 2.19496471]
[2.34641351 2.46242359 3.04918384 2.24460863 1.58035144 2.55553114
0.61721371 1.7907363 0.3763505 1.00948433]

In [16]:

```
1 #Генерация выборки объема n = 100 без вывода
2 for n in [100]:
3     means__100=[]
4     for i in range(5):
5         sample=maxwell_rv.rvs(n)
6         means__100.append(sample)
```

In [17]:

```
1 #Генерация выборки объема n = 1000 без вывода
2 for n in [1000]:
3     means__1000=[]
4     for i in range(5):
5         sample=maxwell_rv.rvs(n)
6         means__1000.append(sample)
```

```
In [18]: 1 #Генерация выборки объема n = 100000 без вывода
          2 for n in [100000]:
          3     means_100000=[]
          4     for i in range(5):
          5         sample=maxwell_rv.rvs(n)
          6         means_100000.append(sample)
```

3.2.1 Нахождение выборочного среднего и выборочной дисперсии геометрического распределения

Выборочное среднее

In [19]:

```
1 #n=5
2 vs__5 = []
3 for i in range(5):
4     vs__5.append(round(np.mean(means__5[i]),6))
5 print(vs__5)
6 #n=10
7 vs__10 = []
8 for i in range(5):
9     vs__10.append(round(np.mean(means__10[i]),6))
10 print(vs__10)
11 #n=100
12 vs__100 = []
13 for i in range(5):
14     vs__100.append(round(np.mean(means__100[i]),6))
15 print(vs__100)
16 #n=1000
17 vs__1000 = []
18 for i in range(5):
19     vs__1000.append(round(np.mean(means__1000[i]),6))
20 print(vs__1000)
21 #n=100000
22 vs__100000 = []
23 for i in range(5):
24     vs__100000.append(round(np.mean(means__100000[i]),6))
25 print(vs__100000)
```

```
[1.988342, 2.067103, 1.381998, 2.058639, 1.21365]
[1.506515, 1.285113, 1.727887, 1.583319, 1.80323]
[1.588683, 1.601758, 1.624953, 1.511346, 1.698355]
[1.566829, 1.647546, 1.574126, 1.629635, 1.579183]
[1.593033, 1.593984, 1.593523, 1.596336, 1.59679]
```

In [20]:

```
1 #Сравнение
2 2*np.sqrt(2/np.pi)
```

Out[20]: 1.5957691216057308

$$M\xi = 2\lambda\sqrt{\frac{2}{\pi}}$$

При $\lambda = 1.0$ $M\xi = 2 \cdot \sqrt{\frac{2}{\pi}} \approx 1.5957691216057308$

Выборочная дисперсия

In [21]:

```
1 #n=5
2 vd__5 = []
3 for i in range(5):
4     vd__5.append(round(np.var(means__5[i]),6))
5 print(vd__5)
6 #n=10
7 vd__10 = []
8 for i in range(5):
9     vd__10.append(round(np.var(means__10[i]),6))
10 print(vd__10)
11 #n=100
12 vd__100 = []
13 for i in range(5):
14     vd__100.append(round(np.var(means__100[i]),6))
15 print(vd__100)
16 #n=1000
17 vd__1000 = []
18 for i in range(5):
19     vd__1000.append(round(np.var(means__1000[i]),6))
20 print(vd__1000)
21 #n=100000
22 vd__100000 = []
23 for i in range(5):
24     vd__100000.append(round(np.var(means__100000[i]),6))
25 print(vd__100000)
```

```
[0.104509, 0.256464, 0.482708, 0.129369, 0.313464]
[0.585148, 0.505908, 0.388416, 0.418193, 0.716524]
[0.461868, 0.452764, 0.410254, 0.445777, 0.275561]
[0.450162, 0.455311, 0.444754, 0.427367, 0.445206]
[0.456508, 0.451218, 0.451222, 0.45127, 0.455822]
```

In [22]:

```
1 #Сравнение
2 (3*nn_ni-8)/nn_ni
```

Out[22]: 0.4535209105296745

$$D\xi = \frac{3\pi - 8}{\pi} \cdot \lambda$$

При $\lambda = 1.0$ $D\xi = \frac{3\pi - 8}{\pi} \approx 0.4535209105296745$

Как видно из полученных значений, чем больше объём выборки, тем менее отличаются выборочное среднее от теоретического математического ожидания и выборочная дисперсия от теоретической дисперсии.

3.2.2 Построение доверительного интервала для выборочного среднего

Положим $\gamma = 0.95$ и найдем доверительный интервал для выборочного среднего.

$$\Phi(c_\gamma) = \frac{\gamma}{2} = 0.475$$

Из таблицы значений функции Лапласа $c_\gamma \approx 1.96$

In [23]:

```
1 #n=5
2 print('n = 5')
3 for i in range(5):
4     print('(', vs__5[i], '-+ 1.96 *', np.sqrt(vd__5[i]/5), ') = (', vs__5[i], '-+', round(1.96*n
5 #n=10
6 print('n = 10')
7 for i in range(5):
8     print('(', vs__10[i], '-+ 1.96 *', np.sqrt(vd__10[i]/10), ') = (', vs__10[i], '-+', round(1.9
9 #n=100
10 print('n = 100')
11 for i in range(5):
12     print('(', vs__100[i], '-+ 1.96 *', np.sqrt(vd__100[i]/100), ') = (', vs__100[i], '-+', roun
13 #n=1000
14 print('n = 1000')
15 for i in range(5):
16     print('(', vs__1000[i], '-+ 1.96 *', np.sqrt(vd__1000[i]/1000), ') = (', vs__1000[i], '-+',
17 #n=100000
18 print('n = 100000')
19 for i in range(5):
20     print('(', vs__100000[i], '-+ 1.96 *', np.sqrt(vd__100000[i]/100000), ') = (', vs__100000[i]
```

n = 5

```
( 1.988342 -+ 1.96 * 0.1445745482441498 ) = ( 1.988342 -+ 0.283366 )
( 2.067103 -+ 1.96 * 0.22647913811210074 ) = ( 2.067103 -+ 0.443899 )
( 1.381998 -+ 1.96 * 0.31071144169470166 ) = ( 1.381998 -+ 0.608994 )
( 2.058639 -+ 1.96 * 0.16085334935897358 ) = ( 2.058639 -+ 0.315273 )
( 1.21365 -+ 1.96 * 0.2503853030830684 ) = ( 1.21365 -+ 0.490755 )
```

n = 10

```
( 1.506515 -+ 1.96 * 0.24189832574865003 ) = ( 1.506515 -+ 0.474121 )
( 1.285113 -+ 1.96 * 0.22492398716010706 ) = ( 1.285113 -+ 0.440851 )
( 1.727887 -+ 1.96 * 0.19708272374817637 ) = ( 1.727887 -+ 0.386282 )
( 1.583319 -+ 1.96 * 0.20449767724842255 ) = ( 1.583319 -+ 0.400815 )
( 1.80323 -+ 1.96 * 0.2676796592944634 ) = ( 1.80323 -+ 0.524652 )
```

n = 100

```
( 1.588683 -+ 1.96 * 0.0679608710950647 ) = ( 1.588683 -+ 0.133203 )
( 1.601758 -+ 1.96 * 0.0672877403395299 ) = ( 1.601758 -+ 0.131884 )
```

*Округлено до 6 знаков после запятой.

3.2.3 Нахождение оптимальности рассматриваемых оценок

Для простоты предположим, что все частоты $p_i, i = \overline{1, n}$ равны единице.

Запишем функцию максимального правдоподобия для закона Максвелла.

$$L(\lambda) = \left(\frac{2}{\pi}\right)^{\frac{n}{2}} \frac{\prod_{i=1}^n x_i^2}{\lambda^{3n}} e^{-\frac{1}{2\lambda^2} \sum_{i=1}^n x_i^2}$$

$$\ln(L(\lambda)) = 2 \sum_{i=1}^n \ln x_i - 3n \ln \lambda - \frac{n}{2} \ln \frac{2}{\pi} - \frac{1}{2\lambda^2} \sum_{i=1}^n x_i^2$$

$$\frac{\partial(\ln L(\lambda))}{\partial \lambda} = -\frac{3n}{\lambda} + \frac{\sum_{i=1}^n x_i^2}{\lambda^3} = 0$$

Переходя к статистическому ряду (не все p_i равны 1, $i = \overline{1, n}$), получим уравнение для нахождения λ :

$$\lambda = \sqrt{\frac{\sum_{i=1}^m p_i x_i^2}{3n}}$$

Оценка методом моментов:

Поскольку по выборке оценивается лишь один параметр, то для нахождения λ используем оценку математического ожидания.

$$M[X] = \overline{X} = 2\lambda \sqrt{\frac{2}{\pi}},$$

где $\overline{X} = \frac{1}{n} \sum_{i=1}^m x_i p_i, \sum_{i=1}^m p_i = n$

Отсюда $\lambda = \sqrt{\frac{\pi}{8}} \overline{X}$