

Содержание

1. [Вероятностные распределения](#)
 - A. [Геометрическое распределение](#)
 - B. [Распределение Максвелла](#)

Вероятностные распределения

In [6]:

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3 from scipy.stats import maxwell
4 import scipy.stats as sts
5 from scipy.stats import geom
6 #from random import random
7 #from collections import Counter
8 #import copy
9 #import math
10 #from math import *
11 from random import *
12 import pandas as pd
13 #import calendar
14 #import statsmodels.api as sm
15
16 plt.style.use('ggplot') # Красивые графики
17 plt.rcParams['figure.figsize'] = (15, 5) # Размер картинок
```

1.1 Геометрическое распределение

1.1.1. Описание основных характеристик распределения

Функция вероятности дискретного распределения: $P_{\xi}(x) = pq^x, x \in \{0, 1, 2, \dots\}$

Математическое ожидание:

$$M\xi = \sum_{k=1}^{\infty} k p q^{k-1} = p \sum_{k=1}^{\infty} k q^{k-1} = p \sum_{k=1}^{\infty} \frac{d q^k}{d q} = p \frac{d}{d q} \left(\sum_{k=1}^{\infty} q^k \right) = p \frac{d}{d q} \left(\frac{q}{1-q} \right) = p \frac{1}{(1-q)^2} = \frac{1}{p}$$


Дисперсия:

$$D\xi = M(\xi - M\xi)^2 = M\xi^2 - (M\xi)^2 = M(\xi(\xi - 1) + \xi) - M\xi^2 = M(\xi(\xi - 1)) + M\xi - (M\xi)^2 = M(\xi(\xi - 1)) +$$

$$M(\xi(\xi - 1)) = p \sum_{k=1}^{\infty} k^2 q^{k-1} = p q \sum_{k=0}^{\infty} \frac{d^2 q^k}{d q^2} = p q \frac{d^2}{d q^2} \left(\sum_{k=0}^{\infty} q^k \right) = p q \frac{d^2}{d q^2} \left(\frac{1}{1-q} \right) = p q \frac{2}{(1-q)^3} = \frac{2q}{p^2}$$

$$D\xi = M\xi^2 + M\xi - (M\xi)^2 = \frac{2q}{p^2} + \frac{1}{p} - \frac{1}{p^2} = \frac{2q-1}{p^2} + \frac{1}{p} = \frac{2q-1+p}{p^2} = \frac{2q-1+1-q}{p^2} = \frac{q}{p^2}$$

```
In [3]: 1 for p in [0.1, 0.4, 0.6, 0.9]:
2         geom_rv = sts.geom(p)
3         sample = geom_rv.rvs(1000)
4         plt.hist(sample, density = True, label='p = {}'.format(p))
5         plt.legend()
6         plt.show()
7     print('Рис. 1: 1 1 1 Гистограмма вероятностей дискретного распределения')
```



Мода M_0 - значение во множестве наблюдений, которое встречается наиболее часто, для дискретной случайной величины определяется с помощью гистограммы вероятностей.

Из гистограмм видно, что $M_0 = 1$

```
In [4]: 1 for p in [0.1, 0.4, 0.6, 0.9]:  
2     n = np.arange(0, 8, 1)  
3     plt.step(n, 1-(1-p)**(n+1), label='p = {}'.format(p))  
4     plt.legend()  
5 plt.show()  
6 print('Рис. 1. 1.1.1. Гистограмма вероятностей дискретного распределения')
```




Рис. 1: 1.1.1, Гистограмма вероятностей дискретного распределения

Медиана Me находится из уравнения $P_{\xi}(x) = 0.5$

$$\begin{cases} p + qp + q^2 p + \dots + q^{Me-1} p \geq \frac{1}{2} \\ q^{Me-1} p + q^{Me} p + q^{Me+1} p + \dots \geq \frac{1}{2} \end{cases}$$

$$\begin{cases} p \frac{1-q^{Me}}{1-q} \geq \frac{1}{2} \\ q^{Me-1} p \frac{1}{1-q} \geq \frac{1}{2} \end{cases}$$

$$\begin{cases} 1 - q^{Me} \geq 2^{-1} \\ q^{Me-1} \geq 2^{-1} \end{cases}$$

$$\begin{cases} q^{Me} \leq 2^{-1} \\ q^{Me-1} \geq 2^{-1} \end{cases}$$

$$\begin{cases} Me \cdot \log_2 q \leq -1 \\ (Me - 1) \log_2 q \geq -1 \end{cases}$$

$$\text{Отсюда } -\frac{1}{\log_2 q} \leq Me \leq 1 - \frac{1}{\log_2 q}$$

Примеры событий, которые могут быть описаны выбранными случайными величинами

Типичные интерпретации геометрического распределения: описывает количество испытаний n до первого успеха при вероятности наступления успеха в каждом испытании p . Если n подразумевается номер испытания, в котором наступил успех, то геометрическое распределение будет описываться следующей формулой:

$$Geom_p(n) = q^{n-1} p$$

Геометрическое распределение считается дискретной версией экспоненциального распределения.

Предположим, что эксперименты Бернулли проводятся через равные промежутки времени. Тогда геометрическая случайная величина X - это время, измеренное в дискретных единицах, которое проходит до того, как мы добьемся первого успеха. Но если мы хотим смоделировать время, прошедшее до того, как данное событие произойдет в непрерывном времени, то подходящим распределением для использования будет экспоненциальное распределение. С математической точки зрения геометрическое распределение обладает тем же свойством без памяти, которым обладает экспоненциальное распределение: в экспоненциальном случае вероятность того, что событие произойдет в течение заданного временного интервала, не зависит от того, сколько времени уже прошло, а событие не произошло; в геометрическом случае вероятность того, что событие произойдет в данный момент (дискретное) времени, не зависит от того, что произошло раньше, потому что эксперимент Бернулли, проведенный в каждый момент времени, не зависит от предыдущих испытаний. Геометрическое распределение полезно для определения вероятности успеха при ограниченном количестве испытаний, что очень применимо к реальному миру, в котором неограниченные испытания редки. Поэтому неудивительно, что различные сценарии хорошо моделируются геометрическими распределениями:

- В спорте, особенно в бейсболе, геометрическое распределение полезно для анализа вероятности того, что отбивающий получит удар, прежде чем он получит три удара; здесь цель - добиться успеха за 3 испытания.
- При анализе затрат и выгод, например, когда компания решает, финансировать ли исследовательские испытания, которые в случае успеха принесут компании некоторую предполагаемую прибыль, цель состоит в том, чтобы достичь успеха до того, как затраты превысят потенциальную выгоду.
- В тайм-менеджменте цель состоит в том, чтобы выполнить задачу за установленный промежуток времени. Другие приложения, подобные вышеупомянутым, также легко создаются. Фактически, геометрическое распределение применяется на интуитивном уровне в повседневной жизни на регулярной основе.

1.1.3 Описание способа моделирования выбранных случайных величин

Существует такой способ реализации метода обратных функций, при котором трудоемкость по крайней мере формально не зависит от p . Действительно, накопленная вероятность $s_{n+1} = p_0 + \dots + p_n$ для геометрического распределения имеет вид

$$s_{n+1} = \sum_{i=0}^n p(1-p)^i = 1 - (1-p)^{n+1}$$

Поэтому событие $\{\xi = n\}$ приобретает вид

$$\begin{aligned} \{\xi = n\} &= \{s_n < \alpha \leq s_{n+1}\} = \{1 - (1-p)^n < \alpha \leq 1 - (1-p)^{n+1}\} = \{(1-p)^{n+1} \leq 1 - \alpha < (1-p)^n\} \\ &= \{(n+1)\ln(1-p) \leq \ln(1-\alpha) < n \cdot \ln(1-p)\} = \{n < \frac{\ln(1-\alpha)}{\ln(1-p)} \leq n+1\}, \end{aligned}$$

и тем самым


$$\xi = \left[\frac{\ln(1-\alpha)}{\ln(1-p)} \right]$$

Эту же формулу можно получить по-другому. Пусть v - случайная величина, имеющая показательное распределение с параметром λ и $\xi = [n]$. Тогда при $n \geq 0$

$$P(\xi = n) = P(n \leq v < n+1) = e^{-n\lambda} - e^{-(n+1)\lambda} = (1 - e^{-\lambda})e^{-n\lambda}.$$

Поскольку случайная величина $\frac{-\ln(1-\alpha)}{\lambda}$ имеет показательное распределение с параметром λ , то взяв $\lambda = -\ln(1-p)$, приходим к формуле $\xi = \left[\frac{\ln(1-\alpha)}{\ln(1-p)} \right]$

```
In [7]: 1 def sample_(N=2500, scale = 0.5):
2         for x in range(N):
3             je = np.log(random())//np.log(1-scale)#Генерирование случайных чисел по формуле из справ
4         return je
5 def Geom(n, p=0.5):
6     x=[sample_(scale=p) for x in range(n)]
7     #print(x)
8     return x
9 plt.hist(Geom(2500,0.5),25, width = 0.1)
10 plt.show()
```



1.2 Распределение Максвелла

1.2.1. Описание основных характеристик распределения

Математическое ожидание:

$$M\xi = \int_0^{\infty} x \sqrt{\frac{2}{\pi}} \frac{x^2}{\lambda^3} e^{-\frac{x^2}{2\lambda^2}} dx = \sqrt{\frac{2}{\pi}} \frac{1}{\lambda^3} \int_0^{\infty} x^3 e^{-\frac{x^2}{2\lambda^2}} dx = 2\lambda^4 \cdot \sqrt{\frac{2}{\pi}} \frac{1}{\lambda^3} = 2\lambda \sqrt{\frac{2}{\pi}}$$

Дисперсия:

$$D\xi = M(\xi - M\xi)^2 = M\xi^2 - (M\xi)^2 = M(\xi(\xi - 1) + \xi) - (M\xi)^2 = M(\xi(\xi - 1)) + M\xi - (M\xi)^2 = M(\xi(\xi - 1))$$

$$M(\xi(\xi - 1)) = \int_0^{\infty} x^2 f(x) dx = \int_0^{\infty} x^2 \sqrt{\frac{2}{\pi}} \frac{x^2}{\lambda^3} e^{-\frac{x^2}{2\lambda^2}} dx = \sqrt{\frac{2}{\pi}} \frac{1}{\lambda^3} \int_0^{\infty} x^4 e^{-\frac{x^2}{2\lambda^2}} dx = \sqrt{\frac{2}{\pi}} \frac{1}{\lambda^3} \cdot 3\lambda^5 \sqrt{\frac{\pi}{2}} = 3\lambda^2$$

$$D\xi = M\xi^2 - (M\xi)^2 = 3\lambda^2 - 4\lambda^2 \cdot \frac{2}{\pi} = \frac{3\pi - 8}{\pi} \lambda^2$$


Также использовались известные интегралы, который был взят из курса физики:

$$\int_0^{\infty} x^3 e^{-x^2/2\lambda^2} dx = \frac{1}{2(\frac{1}{\lambda^2})^2} \cdot 4 = 2\lambda^4$$

$$\int_0^{\infty} x^4 e^{-x^2/2\lambda^2} dx = \frac{3}{8} \sqrt{\pi} \left(\frac{1}{2\lambda^2}\right)^{-\frac{5}{2}} = 3\lambda^5 \sqrt{\frac{\pi}{2}}$$


```
In [8]: 1 for lambd in [0.2,0.5,0.8,1.0]:  
2     maxwell_rv = sts.maxwell(scale = lambd)  
3     x = np.linspace(0,5,100)  
4     cdf = maxwell_rv.cdf(x)  
5     plt.plot(x, cdf, label = 'lambda = {}'.format(lambd))  
6     plt.legend()  
7     print('Рис. 4: График функции распределения')
```

Рис.4: График функции распределения



```
In [9]: 1 for lambd in [0.2,0.5,0.8,1.0]:
2         maxwell_rv = sts.maxwell(scale = lambd)
3         x = np.linspace(0,5,100)
4         pdf = maxwell_rv.pdf(x)
5         k = max(pdf)
6         plt.plot(x, pdf, label = 'lambda = {}'.format(lambd))
7         plt.legend()
8     print('\n')
9     print('Рис 5: График плотности вероятности распределения')
```

Рис.5: График плотности вероятности распределения



Модой абсолютно непрерывного распределения называют любую точку локального максимума плотности распределения.

$$f'(x) = \sqrt{\frac{2}{\pi}} \frac{x^2}{\lambda^3} e^{-\frac{x^2}{2\lambda^2}} = \frac{4x}{\lambda^3 \sqrt{2\pi}} e^{-\frac{x^2}{2\lambda^2}} - \frac{2x^2}{\lambda^3 \sqrt{2\pi}} e^{-\frac{x^2}{2\lambda^2}} \frac{x}{\lambda^2} = 0$$

$$\frac{4x}{\lambda^3 \sqrt{2\pi}} e^{-\frac{x^2}{2\lambda^2}} = \frac{2x^2}{\lambda^3 \sqrt{2\pi}} e^{-\frac{x^2}{2\lambda^2}} \frac{x}{\lambda^2}$$

$$4 = 2x \frac{x}{\lambda^2}$$

$$x^2 = 2\lambda^2$$

$$x = M_0 = \lambda \sqrt{2}$$

Медиана

$$\int_0^{Me} \sqrt{\frac{2}{\pi}} \frac{1}{\lambda^3} x^2 e^{-\frac{x^2}{2\lambda^2}} dx = \frac{1}{2}$$

$$\int_0^{Me} x^2 e^{-\frac{x^2}{2\lambda^2}} dx = \frac{\lambda^3}{2} \sqrt{\frac{\pi}{2}}$$

$$(-\lambda^2 e^{-\frac{x^2}{2\lambda^2}} x + \lambda^3 \sqrt{\frac{\pi}{2}}) \Big|_0^{Me} = \frac{\lambda^3}{2} \sqrt{\frac{\pi}{2}}$$

$$-Me \lambda^2 e^{-\frac{Me^2}{2\lambda^2}} = -\frac{\lambda^3}{2} \sqrt{\frac{\pi}{2}}$$

$$Me \cdot e^{-\frac{Me^2}{2\lambda^2}} = \frac{\lambda^2}{2} \sqrt{\frac{\pi}{2}}$$

$$Me \approx 1,5383\lambda$$

1.2.2. Примеры событий, которые могут быть описаны выбранными случайными величинами

Впервые распределение было определено и использовалось для описания скоростей частиц в идеализированных газах, где частицы свободноперемещаются внутри стационарного контейнера, не взаимодействуя друг с другом, за исключением очень коротких столкновений, в которыхони обмениваются энергией и импульсом друг с другом или со своим тепловым окружением. Термин «частица» в этом контексте относится только к газообразным частицам (атомам или молекулам), и предполагается, что система частиц достигла термодинамического равновесия.Энергии таких частиц следуют так называемой статистике Максвелла – Больцмана, а статистическое распределение скоростей выводится путем приравнивания энергии частиц к кинетической энергии.Распределение Максвелла – Больцмана в основном применяется к скоростям частиц в трех измерениях, но оказывается, что оно зависит только от скорости (величины скорости) частиц. Распределение вероятности скорости частицы указывает, какие скорости более вероятны: частица будет иметь скорость, выбранную случайным образом из распределения, и с большей вероятностью будет находиться в одном диапазоне скоростей, чем в другом.

При тепловом равновесии ($T=\text{const}$) u_{KB} молекул газа остается постоянной и равной $u = \sqrt{\frac{3kT}{m}}$

Это объясняется тем, что в газе устанавливается стационарное статическое распределение молекул по значениям скоростей, называемое распределением Максвелла:

$$f(u) = \frac{dN(u)}{Ndu} = 4\pi\left(\frac{m}{2\pi kT}\right)^{\frac{3}{2}} \cdot u^2 \cdot e^{-\frac{mu^2}{2kT}}$$

В теории вероятностей рассматривается распределения Максвелла, в котором $x = u$ и $\frac{1}{\lambda^2} = \frac{m}{kT}$

Нетипичной интерпретацией распределения Максвелла будут данные, которые представляют время ремиссии (в месяцах) у пациентов с раком мочевого пузыря и первоначально использовались Lee и Wang.

Ремиссия (лат. remissio «уменьшение, ослабление») — период течения хронической болезни, который проявляется значительным ослаблением (неполная ремиссия) или исчезновением (полная ремиссия) её симптомов (признаков заболевания)

1.2.3. Описание способа моделирования выбранных случайных величин

Способ 1: Существует полярный метод (группа полярных методов предназначена для моделирования распределений, так или иначе связанных с двумерными распределениями, инвариантными относительно вращений), где моделируются две независимые случайные величины ξ_1, ξ_2 , каждая из которых имеет распределение $N(0,1)$.

Полярные координаты. Каждая точка $X = (x, y)^T \in R^2 \setminus \{0\}$ может быть однозначно представлена в виде $X = ||X||\bar{e}$, где $\bar{e} = 1$. Полагая $s = ||X||$ и $\bar{e} = (\cos t, \sin t)^T$, где $t \in [0, 2\pi)$, получаем биекцию $\phi : (x, y)^T \rightarrow (s, t)^T$, действующую из $R^2 \setminus \{0\}$ в $(0, \infty) \times [0, 2\pi)$. Конечно, переменные (s, t) являются полярными координатами вектора X , а обратное отображение $\psi : (0, \infty) \times [0, 2\pi) \rightarrow R^2 \setminus \{0\}$ имеет вид $x = s \cos t, y = s \sin t$ с якобианом $\det \psi'(s, t) = s$.

Если теперь рассмотреть случайный вектор $\bar{\xi} \in R^2$ с плотностью распределения $p_\xi(x, y)$ и обозначить r, φ (случайные) полярные координаты этого вектора, то, так как в этом случае $n = 1$, мы получим из (7.1.1), что

$$p_{r,\varphi}(s, t) = s p_\xi(s \cos t, s \sin t) 1_{(0,\infty) \times [0,2\pi)}(s, t). \quad (1.2.3.1)$$

Выражение (1.2.3.1) выглядит особенно просто, если существует такая функция

$f : (0, \infty) \rightarrow (0, \infty)$, что $p_\xi(x, y) = f(\sqrt{x^2 + y^2})$. В этом случае, очевидно,

$$p_{r,\varphi}(s, t) = s f(s) I_{(0,\infty) \times [0,2\pi)}(s, t) = 2\pi s f(s) I_{(0,\infty)}(s) \frac{1}{2\pi} I_{[0,2\pi)}(t). \quad (1.2.3.2)$$

Это значит, что случайные величины r и φ независимы, $\varphi \in U(0, 2\pi)$, а r имеет плотность распределения

$$p_r(s) = 2\pi s f(s), s > 0$$

Действительно, поскольку совместная плотность распределения ξ_1, ξ_2 имеет вид

$$p(x, y) = \frac{1}{2\pi} e^{-\frac{x^2+y^2}{2}}, x, y \in R,$$

то, как следовательно из вышенаписанного, полярный радиус r и полярный угол φ случайного вектора (ξ_1, ξ_2) независимы,

причем полярный угол равномерно распределен на $[0, 2\pi)$, а полярный радиус имеет распределение Рэлея ($p(x) = x e^{-\frac{x^2}{2}}$, $x > 0$).

Отсюда, применяя моделирующую формулу ($\xi = \sqrt{-2\ln(\alpha)}$), сразу же приходим к представлению


$$\begin{aligned} \xi_1 &= \sqrt{-2\ln(\alpha_1)} \cos(2\pi\alpha_2), \\ \xi_2 &= \sqrt{-2\ln(\alpha_1)} \sin(2\pi\alpha_2), \end{aligned}$$

где $\alpha_1, \alpha_2 \in U(0, 1)$

В итоге получаем следующий алгоритм:

In [10]:

```
1 %matplotlib inline
2 import random
3 import pandas as pd
4 import math
5 from scipy import stats
6 import sys
7 plt.style.use('ggplot') # Красивые графики
8 plt.rcParams['figure.figsize'] = (15, 5) # Размер картинок
9 N=10000
10 random.seed(123)
11 epsilon = sys.float_info.epsilon
12
13 def box_muller():
14     u1, u2 = 0.0, 0.0
15     while u1 < epsilon or u2 < epsilon:
16         u1 = random.random()
17         u2 = random.random()
18
19     n1 = math.sqrt(-2 * math.log(u1)) * math.cos(2 * math.pi * u2)
20     n2 = math.sqrt(-2 * math.log(u1)) * math.sin(2 * math.pi * u2)
21     return n1, n2
22
23 # Use KS to test
24 samples = [box_muller()[0] for x in range(N)]
25 test_stat, pvalue = stats.kstest(samples, 'norm', args=(0, 1), N=N)
26
27 # Plot our samples against our reference distribution
28 plt.hist(samples, 30, width = 0.1)
29 plt.show()
```



Стоит заметить, что данный способ достаточно быстр.

Я бы ещё подметил тот факт, что распределение Максвелла с параметром $\lambda = 1$ очень схоже с $N(0,1)$:

$$f(x) = \sqrt{\frac{2}{\pi}} e^{-\frac{x^2}{2}} \quad x^2 - \text{Максвелла}$$

$$f(x) = \sqrt{\frac{2}{\pi}} e^{-\frac{x^2}{2}} \cdot \frac{1}{2} - N(0, 1)$$

Способ 2: По определению, случайный вектор $\bar{\xi} = (\xi_1, \xi_2)^T$ равномерно распределен на единичной окружности S^1 с центром в нуле, если $\xi_1^2 + \xi_2^2 = 1$ с вероятностью 1 и если полярный угол φ вектора $\bar{\xi}$ равномерно распределен на $[0, 2\pi)$. Из этого определения сразу же следует моделирующая формула для равномерного распределения на S^1 :

$$\begin{aligned}\xi_1 &= \cos(2\pi\alpha) \\ \xi_2 &= \sin(2\pi\alpha)\end{aligned}\quad (1.2.3.3)$$

Вычисление двух тригонометрических функций, однако, может оказаться трудоемкой операцией. Стандартной альтернативой формуле (1.2.3.3) является использование метода отбора для моделирования равномерного распределения в единичном круге $B_1(0) = \{(x, y) : x^2 + y^2 < 1\}$ с центром в нуле с последующей нормировкой результата. Формальное обоснование этой процедуры представим ниже.

Аналогично полярным координатам на плоскости, каждый ненулевой вектор $X = (x, y, z)^T \in R^3$ может быть однозначно представлен в виде $X = ||X||\bar{e}$, где

$$\bar{e} = (\cos(t)\cos(u), \sin(t)\cos(u), \sin(u))^T, t \in [0, 2\pi), u \in [-\pi/2, \pi/2].$$

Это, конечно, соответствует переходу от евклидовой системы координат (x, y, z) к сферической системе (s, t, u) со сферическим радиусом $s = ||X||$, долготой s и широтой u . Хорошо известно, что якобиан обратного отображения равен $s^2 \cos(u)$.

Поэтому, если случайный вектор $\bar{\xi} = (\xi_1, \xi_2, \xi_3)^T$ имеет плотность распределения $p_{\xi}(x, y, z)$, то сферические координаты r, φ, θ этого вектора имеют совместную плотность

$$pr, \varphi, \theta(s, t, u) = p_{\xi}(s \cos(t) \cos(u), s \sin(t) \cos(u), s \sin(u)) s^2 \cos(u), \quad (1.2.3.4)$$

сосредоточенную в области $(0, \infty) \times [0, 2\pi) \times (-\pi/2, \pi/2)$. В случае, когда

$$p_{\xi}(x, y, z) = f(\sqrt{x^2 + y^2 + z^2}), \quad (1.2.3.5)$$

равенство (1.2.3.4) приобретает вид

$$p_{r, \varphi, \theta}(s, t, u) = 4\pi s^2 f(s^2) I_{(0, \infty)}(s) \frac{1}{2\pi} I_{(0, 2\pi)} \frac{\cos(u)}{2} I_{(-\frac{\pi}{2}, \frac{\pi}{2})}.$$

Таким образом, случайные величины r, φ и θ оказываются независимыми, причем долгота φ равномерно распределена на $(0, 2\pi)$, плотность $p_r(s)$ распределения r равна $4\pi s^2 f(s^2)$, а плотность $p_{\theta}(u)$ распределения широты θ сосредоточена на $(-\frac{\pi}{2}, \frac{\pi}{2})$ и равна на этом интервале $0.5 \cos(u)$.

Например, если $\bar{\xi} = (\xi^1, \xi^2, \xi^3)^T$ — случайный вектор с независимыми $N(0, 1)$ -распределенными координатами, то его

In [16]:

```
1 def Maxwell(n, lambd = 1):
2     x = [sample_(scale = lambd) for x in range(n)]
3     y=[sample_(scale = lambd) for x in range(n)]
4     z=[sample_(scale = lambd) for x in range(n)]
5     l = []
6     #print(x)
7     for i in range(n):
8         l.append(np.sqrt(x[i]**2+y[i]**2+z[i]**2))
9     return l
10 # Our sample function of  $N(0,1)$  using Equation (2)
11 def sample_(N = 3000, scale = 1):
12     return scale*2.0*np.sqrt(N)*(sum(randint(0,1) for x in range(N))/N-0.5)
13 plt.hist(Maxwell(3000,5),30, width = 0.1)
14 plt.show()
```

